

यह एक सिंगल 8 GB बोर्ड पर ऑफलाइन हिंदी वॉइस असिस्टेंट बनाते समय आई समस्याओं और उनमें से प्रत्येक को खोजने की लागत का विवरण है। इनमें से तीन समस्याओं के कारण मॉडल बदलना पड़ा। कई समस्याएँ केवल इसलिए सामने आईं क्योंकि हमने ऐसी चीजों की माप की जिनकी माप ज़रूरी नहीं थी — और उनमें से दो समस्याएँ डिवाइस में नहीं बल्कि हमारी अपनी माप में ही गलतियाँ थीं। यहाँ दिए गए सभी आंकड़े इसी बोर्ड पर लिए गए हैं।

जिन मॉडल में हमने बदलाव किए, और उनके कारण

चार बदलाव

हिंदी स्पीच रिकग्निशन वर्णमाला के नौ व्यंजनों को छोड़ रहा था

समस्या शब्दों में से अक्षर गायब होकर आ रहे थे, और हमेशा वही अक्षर: मुझे की जगह मे, कुछ की जगह कु, समझ की जगह सम। सही sample rate पर साफ audio होने से भी कोई फर्क नहीं पड़ा।

कारण जिस ONNX export से हमने शुरुआत की थी, उसमें 89-token की vocabulary hardcoded थी। असली model में 257 हैं। देवनागरी के नौ व्यंजन इस table से पूरी तरह गायब थे (झ छ घ ठ ढ ण ष ड ज), और चूँकि CTC blank index की गणना vocabulary की लंबाई के रूप में की जाती है, इसलिए index 88 से ऊपर model की अन्य सभी output classes को भी चुपचाप हटा दिया गया था।

सुधार checkpoint को AI4Bharat के indic-conformer-600m-multilingual तक ट्रैक किया गया और उसी **model** के एक public int8-quantised export पर स्विच किया गया जो पूरी 257-token Hindi vocabulary और उसके language mask के साथ आता है। Model family नहीं बदली — export बदला है।

परिणाम पहले फेल होने वाले वाक्यों पर round-trip synthesis→recognition अब character-for-character मैच देता है।

लैंग्वेज मॉडल ने एक क्लिनिकल नेगेशन को उलट दिया

समस्या रिट्रीव किए गए पेज में “Do not bathe a baby until its weight is 2000 gm” नियम शब्द-प्रति-शब्द मौजूद होने के बावजूद, मॉडल ने उत्तर दिया कि बच्चे को should be bathed daily until its weight reaches 2000 grams। किसी स्वास्थ्य उपकरण पर यह कमज़ोर उत्तर नहीं है; यह एक खतरनाक उत्तर है।

कारण हमने केवल मेमोरी बचाने के लिए qwen2.5:1.5b पर स्विच किया था। इस साइज़ में यह मॉडल केवल कमज़ोर ही नहीं था — नेगेशन के मामले में यह अनसेफ था।

सुधार एक ही सवाल पर चार कैंडिडेट का परीक्षण किया और साइज़ के आधार पर नहीं, बल्कि व्यवहार के आधार पर चयन किया:

मॉडल	रेजिडेंट	निषेध परीक्षण पर व्यवहार
qwen2.5:1.5b	817 MB	निषेध उलटा हो गया — असुरक्षित
qwen2.5:3b	1684 MB	“I do not have this information” — सुरक्षित लेकिन गलत
qwen3-vl:2b	3084 MB	सही, लेकिन बात को घुमाता है और फिट नहीं बैठेगा
qwen3:1.7b	921 MB	सही और संक्षिप्त — चुना गया

qwen3:1.7b, उस विज़न मॉडल का केवल-टेक्स्ट (text-only) सहोदर (sibling) है जिसे हम चला रहे थे। कैमरा-रहित एप्लिकेशन उस मॉडल के CLIP टॉवर का उपयोग कभी नहीं कर पाया, जो हर स्टार्टअप पर 322 MB रिज़र्व्ड विज़न बफर और 721 अतिरिक्त टेंसर्स (tensors) की लागत ले रहा था। इसे हटाने से **2.2 GB** जगह खाली हुई — यह उस स्थिति के बीच का अंतर है जहाँ लगभग छह प्रश्नों के बाद बोर्ड स्वेप-थ्रैशिंग (swap-thrashing) करने लगता था, उपलब्ध मेमोरी घटकर 60 MB रह जाती थी और ऑडियो प्लेबैक अनइंटरप्टिबल स्लीप (uninterruptible sleep) में रुक जाता था, और 34 MB स्वेप की एक स्थिर स्थिति (steady state) के बीच का अंतर है।

समय की कमी के कारण हिंदी वॉइस का चयन सुनकर नहीं, बल्कि जल्दबाजी में करना पड़ा

समस्या पाइपलाइन में सिंथेसिस सबसे बड़ा चरण था और जो वॉइस हमें सबसे अच्छी लगी, वह दिए गए टाइम बजट में नहीं चल सकी।

सुधार इसी डिवाइस के अपने स्पीकर के माध्यम से तीनों कैंडिडेट को उन्हीं वाक्यों पर चलाया गया:

आवाज़	सिंथेसिस	वज़न	रेट	लाइसेंस
MMS VITS	~1.0 s	250 MB	16 kHz	CC-BY-NC
Piper	0.48 s	64 MB	22 kHz	CC-BY-NC-SA
IndicF5	5.8–10.4 s	1.4 GB	24 kHz	MIT

IndicF5 की आवाज़ सबसे साफ़ लगी और इसका लाइसेंस भी सबसे बेहतर है, इसलिए इसे छोड़ने से पहले इस पर पूरी तरह काम किया गया: fp16 हाफ प्रेसिजन और autocast दोनों में NaN पर डाइवर्ज हो जाता है, solver steps को आठ से कम करने पर आवाज़ में साफ़ गिरावट आती है, और रेफ़रेंस क्लिप को 8 s से घटाकर 3 s करने पर स्पीड तीन गुना ज़रूर हो गई। इसके बावजूद, छह शब्दों के जवाब के लिए न्यूनतम समय 5.8 s था, जबकि पूरे पाइपलाइन के लिए बजट 5–8 s का था। यह बड़े बोर्ड के लिए सही अपग्रेड है, इस बोर्ड के लिए नहीं। Piper की हिंदी आवाज़ AI4Bharat के indicInp कॉर्पस पर ट्रेन की गई है, इसलिए इसकी Indic provenance सुरक्षित है। इसका लाइसेंस non-commercial है जिसे बिक्री से पहले बदलना होगा।

अनुवादक बोले जाने वाले उत्तर का अंतिम हिस्सा काट रहा था

समस्या पैतालीस शब्दों का एक उत्तर निर्देश के बीच में ही रुक गया: “...that requires immediate intervention” को “... जिसके लिए तत्काल हस्तक्षेप” के रूप में बोला गया, जिसमें क्रिया गायब थी।

कारण डिकोडर की अधिकतम output length 64 tokens थी। हिंदी में उस अंग्रेजी की तुलना में अधिक tokens लगते हैं जिससे अनुवाद किया जाता है, इसलिए वाक्य के बीच में ही सीमा समाप्त हो गई।

सुधार इसे बढ़ाकर 192 कर दिया गया। greedy decoding के साथ इसकी कोई लागत नहीं आती जब तक कि output वास्तव में लंबा न हो। IndicTrans2 को कभी नहीं बदला गया।

बोर्ड में अपने आप में हैं

पाँच समस्याएँ

बोर्ड का बटन यह रिपोर्ट नहीं कर सकता कि उसे दबाकर रखा गया है

समस्या लगभग आठ सेकंड से अधिक लंबा हर प्रश्न कट जाता था। यह सुनने में जितना बुरा था, उससे कहीं ज्यादा गंभीर था: “... डॉक्टर या नर्स मौजूद नहीं हैं” इस कटने के कारण अपनी नकार (negation) खो बैठा, translator ने बचे हुए हिस्से को the doctor is present के रूप में अनुवादित कर दिया, और इसके साथ उत्तर उलट गया। “गलत उत्तर” की कई रिपोर्ट्स का कारण इसी एक pin से जुड़ा हुआ निकला।

कारण raw polling और edge callbacks दोनों के साथ बार-बार माप की गई, जिनके परिणाम एक जैसे रहे: ट्रिगर pin प्रेस करने पर high हो जाता है और जब बटन भौतिक रूप से अभी भी दबा हुआ होता है, तब लगभग 7.8 s (अलग-अलग रन में 7.76 / 7.78 / 7.79 / 7.81 / 7.90 / 7.90 / 7.91 s) के बाद low हो जाता है, और कभी वापस high नहीं होता। रिकॉर्डर अपने आप में अठारह सेकंड से ज्यादा समय तक सुचारु रूप से चलता है, इसलिए यह pin की समस्या है, सॉफ्टवेयर की नहीं। Jetson.GPIO का pull-up अनुरोध इस प्लेटफॉर्म पर अनदेखा कर दिया जाता है; इसे वास्तव में बदलने के लिए device-tree pinmux को रीबिल्ड करने की आवश्यकता है, और एक pull-down भी उस high लेवल को ठीक नहीं कर पाता जो वैसे भी डीके(decay) हो जाता है।

सुधार हार्डवेयर से लड़ने के बजाय इंटरैक्शन को हार्डवेयर के अनुसार दोबारा डिजाइन किया गया: एक बार प्रेस करें, बोलें, बोलना बंद करें। रिकॉर्डिंग प्रत्येक रिकॉर्डिंग की शुरुआत में कमरे के अपने नॉइज़ फ्लोर से कैलिब्रेट किए गए थ्रेशोल्ड के आधार पर 3.5 s की साइलेंस के बाद समाप्त होती है। दोबाराप्रेस करने पर यह अभी भी तुरंत रुक जाती है। 3.5 s न कि 2.0 s, क्योंकि 2.0 s पर वाक्यों के बीच की सामान्य साँस ने प्रश्न को समाप्त कर दिया और मॉडल तक पहुँचने वाले fragment में कोई प्रश्न नहीं था।

हर सेशन का पहला प्रश्न सबसे धीमा था

समस्या पहले प्रश्न पर रिकॉग्निशन में 6–8 s लगे और उसके बाद लगभग 0.65 s। यूजर को सबसे पहले मिलने वाला अनुभव ही सबसे खराब अनुभव था।

कारण वार्म-अप ने सीधे ONNX सेशन का इस्तेमाल किया, इसलिए पहले वास्तविक अनुरोध को फिर भी ऑडियो लाइब्रेरी के जस्ट-इन-टाइम कंपाइलेशन का सामना करना पड़ा। ट्रांसलेटर का कोई वार्म-अप नहीं हुआ था और इसके अपने कंस्ट्रक्टर के भीतर वार्म-अप करना पर्याप्त नहीं था — सिंथेसिस इसके बाद एक और रनटाइम सेशन बनाता है, इसलिए वार्म-अप को हर इंजन चालू होने के बाद एक बार चलना होगा।

सुधार हर इंजन को उसी एंटी पॉइंट के माध्यम से वार्म करें जिसका उपयोग वास्तविक अनुरोध करते हैं, उन सभी के लोड होने के बाद, और दो-शब्द के ग्रीटिंग के बजाय एक पूरे वाक्य के साथ, क्योंकि कर्नेल का चयन वास्तव में दिए गए शेष के लिए किया जाता है।

परिणाम पहला प्रश्न 0.66 s। पहले अनुरोध पर और उसके बाद के हर अनुरोध पर ट्रांसलेशन 0.51 s।

लंबे सवालों का साफ तौर पर विफल होने के बजाय बकवास में बदल जाना

समस्या रिकॉग्निजर को छोटे कथनों पर ट्रेन किया गया है। ज्ञात टेक्स्ट से तुलना करने पर: 11.0 s पर 95% कैरेक्टर बचे, 20.2 s पर 70%, 28.6 s पर 52%, 38.2 s पर 42% — और रुकने के बजाय पिछला हिस्सा बकवास में बदल गया।

कारण अटेंशन, शेष लिमिट नहीं: ONNX ग्राफ में हर एक्सिस डायनेमिक है।

सुधार लंबे ऑडियो को बारह सेकंड की सीमाओं के आसपास विभाजित किया जाता है, प्रत्येक सीमा को 1.5 s के भीतर सबसे शांत बिंदु पर थोड़ा खिसकाया जाता है ताकि जोड़ शब्दों के बीच के अंतराल में आएँ, और प्रत्येक chunk को अपने आप सामान्यीकृत और डिकोड किया जाता है।

परिणाम परीक्षण की गई प्रत्येक लंबाई पर 95%, 1.3–1.9 s में।

स्क्रीन पर देवनागरी बिल्कुल नहीं आ पाई

समस्या डिस्प्ले लाइब्रेरी बिना किसी शेपिंग के प्रति कोड पॉइंट एक बिटमैप ग्लाइफ ब्लिट कर रही थी। मात्राएँ लाइन के ऊपर अलग तैर रही थीं, प्री-बेस इ-मात्रा का पुनः क्रम नहीं हुआ (मासिक मासक के रूप में दिखा), और संयुक्त अक्षर नहीं बने (स्तनपान सतनपान के रूप में दिखा)।

सुधार HarfBuzz के साथ टेक्स्ट को शेपिंग करके एक वन-बिट इमेज में बदला जाता है और डिस्प्ले बफर में पुश किया जाता है — दोनों लिपियों के लिए सही, प्रति अपडेट लगभग 33 ms। स्क्रीन इंटरैक्शन के बीच में भाषाओं के बीच भी स्विच हो जाती थी, हिंदी बहाल होने से पहले अंग्रेजी अनुवाद और फिर अंग्रेजी उत्तर दिखाती थी; वे पाइपलाइन के अंदरूनी हिस्से थे जो इंटरफेस में लीक हो रहे थे, और जो वर्कर हिंदी में पूछता है उसे अब केवल हिंदी दिखाई देती है।

पावर मोड, और बाकी बची लेटेंसी कहाँ गई

समस्या जनरेशन (generation) पर सबसे ज्यादा लागत आ रही थी और बोर्ड से उसकी पूरी क्षमता का इस्तेमाल नहीं लिया जा रहा था।

सुधार MAXN_SUPER सेट किया गया, जिसे रीबूट (reboot) के बाद भी बनाए रखने के लिए स्थायी कर दिया गया; और अब जवाब पूरा होने के बाद बोलने के बजाय, जनरेट होते ही वाक्य-दर-वाक्य बोला जाता है।

परिणाम जनरेशन 35.8 tokens/s, जो 52 °C पर दस रन (runs) में स्थिर रहा। लैंग्वेज मॉडल 4.34 s → 2.51 s। पहली ऑडियो 5.37 s → 4.05 s। सिंथेसिस (synthesis) को अलग से GPU पर स्थानांतरित किया गया: 4.3 s → 0.9 s।

मैनुअल एक ऐसे **PDF** के रूप में आया जिसे उल्टे क्रम में प्रिंट किया गया था

समस्या स्रोत PDF से निकाली गई टेक्स्ट एक साथ चार अलग-अलग तरीकों से भ्रष्ट थी: शब्दों के भीतर अक्षर दो बार हो गए थे, रनिंग हेड उल्टे हो गए थे, पूरे पेज अक्षर-दर-अक्षर उल्टे थे (Home Visit Form के लिए mroF tisiV emoH), और बुलेट मार्कर 'u' अक्षर में बदल गए थे।

सुधार निकाली गई पूरी किताब का पेज-दर-पेज ऑडिट किया गया और लोड होने पर इसे ठीक किया गया: 82 दो बार आए शब्द, 78 उल्टे हेड, 4 पूरी तरह उल्टे पेज और 35 बुलेट। स्रोत PDF के 88 पेजों में से, 12 से कोई टेक्स्ट नहीं मिला — वे इमेज हैं या खाली हैं।

परिणाम 72 पेज इंडेक्स किए गए हैं। उल्टे पेजों में से चार होम-विजिट चेकलिस्ट हैं; माप के बाद उन्हें जानबूझकर इंडेक्स से बाहर रखा गया, क्योंकि उन्हें शामिल करने से सेप्सिस के खतरे के लक्षणों की साफ सूची रिट्रीव्ड context से बाहर हो गई और मूल्यांकन 9/10 से गिरकर 8/10 हो गया।

असली एक्यूरेसी समस्या कहाँ छिपी थी

समस्या 52 प्रश्नों के सेट पर — पेज 20 से आगे मैनुअल के हर पेज से एक प्रश्न — केवल 42 के उत्तर दिए गए और केवल 30 उस पेज से आए जिसके विरुद्ध प्रश्न लिखा गया था।

कारण रैंकिंग नहीं थी। relevance gate बंद होने पर, 71% प्रश्नों के लिए सही पेज पहले से ही शीर्ष तीन में था। यह vocabulary थी: प्रश्न हिंदी में पूछा जाता है और किताब अंग्रेजी में लिखी गई है, और translator ने उस शब्द का रोज़मर्रा का अर्थ चुनना जारी रखा जिसका मैनुअल में तकनीकी रूप से उपयोग होता है। इसके बाद प्रश्न और उत्तर में कोई भी शब्द साझा नहीं हुआ।

सुधार आठ substitutions, जिनमें से प्रत्येक को वास्तविक प्रश्न का दोनों तरफ से अनुवाद करके और उस wording को रखकर चुना गया जिससे वह term उत्पन्न हुआ जिस पर index वास्तव में बना है।

महिला क्या कहती है	ट्रांसलेटर ने क्या आउटपुट दिया	मैनुअल में क्या छपा है
आशा	the role of hope (आशा)	ASHA
पानी की कमी	water scarcity, no water (पानी की कमी)	dehydration — on all four pages that answer it
यौन संक्रमण	sexual transition (लैंगिक संक्रमण)	sexually transmitted infection
दम घुटना	choking (गला घुटना)	asphyxia
छत्ता	cut open (चीरा लगाना)	IUCD
नसबंदी	vasectomy — even for a woman (पुरुष नसबंदी — वह भी महिला के लिए)	sterilisation
पसली चलना	walk rib (पसली चलना)	chest indrawing

परिणाम 52 में से 42 → 50 का उत्तर दिया गया; जिस पेज से प्रश्न आया था, वहाँ से 30 → 39 का उत्तर दिया गया। इनमें से एक समस्या कॉस्मेटिक नहीं थी: यह पूछे जाने पर कि सांस की बीमारी के लिए ASHA कौन सी दवा दे सकती है, डिवाइस न्यूमोनिया के लिए chloroquine or ACT — मलेरिया की दवाएँ — उत्तर दे रहा था। ASHA और worker शब्द उसके लिए लिखे गए मैनुअल के लगभग हर पेज पर आते हैं, इसलिए वे दवा का नाम बताने वाली वर्गीकरण तालिका के ऊपर सेशन उद्देश्यों का एक पेज और टीबी के दो पेज साथ ले आए थे। प्रश्न और इंडेक्स दोनों से हटाए जाने पर, अब वही प्रश्न **Cotrimoxazole** उत्तर देता है।

रिकॉग्निज़र एक ही जवाब दो बार नहीं देता है

समस्या 52 प्रश्नों के एक पास (pass) में कहा गया कि 45 कीवर्ड्स बचे; दूसरे में 50 कहा गया। इनमें से कोई भी माप नहीं था।

कारण रिकॉग्निज़र Deterministic नहीं है। एक ही प्रश्न, उसी तरह बोलने पर, तीन प्रयासों में फसली, पसी और फसली बनकर आया।

सुधार स्पीच से जुड़ी हर चीज़ को अब 156 रिकॉग्निज़र — सभी 52 प्रश्न, हर एक तीन बार — पर मापा जाता है, न कि एक पास पर। उस साक्ष्य के आधार पर दो सीमित सुधार जोड़े गए: एक छूटा हुआ अक्षर edit distance का पूरा पॉइंट लेता है और confusable-slip लिमिट को कभी पार नहीं कर सकता था, इसलिए स्तनपान के रूप में सुना गया स्नपान वैसे ही बिना बदलाव के निकल गया; और दो अनुस्वार/नासिक्य चिह्न एक-के-बाद-एक लिखे जाने पर कोई हिंदी शब्द नहीं बनाते हैं, लेकिन दो अलग-अलग कैरेक्टर्स होने के कारण, उस नियम से बचकर निकल गए जो रिपीट होने वाले कैरेक्टर्स को हटाता है।

परिणाम सुधार से पहले 97% कीवर्ड्स बचे, सुधार के बाद 99%।

एक नियम जो शब्दों को सुधार रहा था, वही एक शब्द को बिगाड़ भी रहा था

समस्या डिवाइस ने “what can an ASHA do **to** a pregnant woman” का उत्तर दिया, बजाए “to help a pregnant woman” के।

कारण अक्षरों की पुनरावृत्ति (stuttering) को ठीक करने वाले एक नियम के कारण मदद — help — सिक्कड़ कर मद बन गया, और वाक्य से help गायब होने के बाद ट्रांसलेटर ने उसे अंग्रेजी से भी हटा दिया।

सुधार दो बार आने वाली मात्रा (vowel sign) या अनुस्वार (nasal) कभी भी सही हिंदी वर्तनी नहीं हो सकते, इसलिए उन्हें अभी भी हटाया जाता है। दोहराया गया व्यंजन (consonant) सही हो सकता है, इसलिए अब उसे केवल वहीं संक्षिप्त किया जाता है जहाँ ऐसा करने से कोई क्लिनिकल term वापस मिल जाए। 156 recognitions में यह नियम पाँच अलग-अलग tokens पर ट्रिगर होता है: यह उनमें से तीन को सुधार देता है और अब मदद को नहीं तोड़ता।

डिवाइस ने गर्भवती महिला को गर्भनिरोधक सलाह दी

समस्या यह पूछने पर कि एनीमिया से पीड़ित गर्भवती महिला को किन बातों का ध्यान रखना चाहिए, डिवाइस ने कहा कि उसे IUCD से बचना चाहिए। यह पूछने पर कि उसे पहले महीनों में किन जाँचों की आवश्यकता है, जवाब मिला कि यह पुष्टि करने के लिए कि IUCD अपनी जगह पर है, मासिक pelvic exam की आवश्यकता है। यह पूछने पर कि कौन सी गोली एनीमिया की रोकथाम करती है, जवाब मिला कि वह Mala N या Mala D है — जो एक गर्भनिरोधक गोली है। इनमें से किसी भी बात में कोई हिचकिचाहट या संदेह (hedged) नहीं था।

कारण यह मॉड्यूल बच्चों के बारे में है। इसमें गर्भनिरोध पर दस पेज हैं और एंटीनेटल केयर (antenatal care) पर एक भी नहीं, इसलिए pregnant woman सर्च करने पर गर्भनिरोध वाले पेज सही नीयत से सामने आ जाते हैं। इनके बीच कोई threshold इन्हें अलग नहीं करता: प्रति टर्म इनकी relevance, 4.1 से 6.1, असली प्रश्नों की सीमा के भीतर ही है, और कवरेज भी इन्हें अलग नहीं करती — 0.48 से 0.79, जबकि असली प्रश्न 0.39 से शुरू होते हैं।

सुधार नियम वही है जो है। गर्भधारण न करने के तरीके के बारे में कोई पेज उस महिला के बारे में पूछे गए सवाल का जवाब नहीं दे सकता जो पहले से ही गर्भवती है, इसलिए इसे context से हटा दिया गया है; यदि और कुछ retrieve नहीं हुआ तो डिवाइस कह देता है कि उसके पास यह जानकारी नहीं है, जो इस मैनुअल के लिए सच है। मैनुअल में उसके बारे में जो जानकारी मौजूद है — गर्भावस्था में मलेरिया, गर्भावस्था में TB का इलाज, उसका टिटनेस का टीका — उसे छुआ नहीं गया है।

खुद के बारे में बात करने वाले उत्तर और अनुवाद में खोए नाम

समस्या कई ऐसी कमियाँ जो तब सामने आती हैं जब उत्तर को किसी ऐसे व्यक्ति के सामने पढ़कर सुनाया जाता है जो स्क्रीन नहीं देख सकता। मॉडल ने शुरुआत YES से की और फिर सही बात कही कि गोलियों की सलाह not नहीं दी जानी चाहिए — विरोधाभास पहले आया, जिस पर वह कार्रवाई करती। इसने कहा the context does not provide information, और डिवाइस ने बिना चूके context शब्द का अनुवाद उस वर्कर को सुना दिया जिसे कभी इसके बारे में नहीं बताया गया था। इसने मैनुअल के अपने टीचिंग स्केफोल्डिंग को ही उत्तर के रूप में दोहरा दिया: Step 3 of the session includes... और उसके हाथ में दी जाने वाली चीजों के नामों का अनुवाद उनके सामान्य अर्थ वाले शब्दों में हो गया: Gentian violet paint बन गया जेंटियन बैंगनी रंग — एक बैंगनी रंग; the cord बन गया डोर, यानी रस्सी; zinc बन गया जस्ता, यानी धातु।

सुधार मॉडल चाहे दिए गए शब्दों का इस्तेमाल करे या अपने खुद के इनकार (refusals) को पहचान लिया जाता है। सीधे दिए जाने वाले फ़ैसले और स्केफोल्डिंग को हटा दिया जाता है — और बार-बार हटाया जाता है, क्योंकि मॉडल इन्हें एक के ऊपर एक जोड़ देता है ("The answer is: Step 3 of the session includes..." में ऐसे दो हिस्से हैं)। जहाँ काम बन सके वहाँ नामों को इंग्लिश से ही निर्देशित किया जाता है और जहाँ ऐसा न हो वहाँ हिंदी में सुधारा जाता है, क्योंकि कोई अनुवादक किसी नाम को कैसे प्रस्तुत करता है, यह उसके आस-पास के वाक्य पर निर्भर करता है।

परिणाम सभी पचास उत्तरित प्रश्नों पर जाँच की गई: ठीक वही उत्तर बदले गए जिन्हें बदलने की ज़रूरत थी।

एक ऐसा अस्पष्ट अंग्रेज़ी शब्द जिससे गलत पदार्थ का नामकरण हो गया

समस्या डाइहाइड्रेशन के लक्षणों में से एक के लिए डिवाइस पर खराब शराब पीना प्रदर्शित हुआ — जिसका अर्थ "drinking alcohol badly" था।

कारण बिना कर्म (object) वाला अंग्रेज़ी drink शब्द अस्पष्ट है, और अनुवादक इसे इतनी बार alcohol के रूप में अनुवादित कर देता है कि यह समस्या बन जाती है।

समाधान क्रिया (verb) को एक कर्म दें। डोमेन के बाकी अस्पष्ट शब्दों — stool, labour, discharge, delivery, passing, water breaking — की भी इसी तरह जाँच की गई और वे सभी संदर्भ के अनुसार सही रूप में अनुवादित हो गए, इसलिए यह एक ग्लोस इसे एक शब्दावली (glossary) बनाने के बजाय एक ही छोटे बदलाव तक सीमित रखा गया। इसे दो बार ठीक करना पड़ा: पहले सुधार में क्रिया के बाद आने वाली क्रिया-विशेषण (adverb) वाली स्थिति (drinking poorly) को तो ठीक कर लिया गया, लेकिन संज्ञा से पहले आने वाले विशेषण (poor drinking) को नहीं पकड़ा जा सका, जबकि मैनुअल में असल में इसी रूप में लिखा गया है।

हमने अपने ही मापों के बारे में क्या गलत समझा

चार मुद्दे

एक क़ैश जो उस इकलौते रास्ते के भीतर छिपा रहा जिस पर टेस्ट नहीं चले थे

समस्या हर स्ट्रीम किया गया उत्तर "this is not in the ASHA manual" (यह आशा मैनुअल में नहीं है) बन गया, जबकि रिट्रीवल का स्कोर 4.75 था और सही पेज हाथ में था।

कारण वर्कर श्रेड के अंदर एक ऐसा वेरिएबल इस्तेमाल किया गया जिसे उसमें कभी पास ही नहीं किया गया था। एक्सेप्शन को दबा दिया गया और विफलता बिल्कुल किसी रिफ्यूजल (मनाही) जैसी दिख रही थी। यह किसी की नज़र में इसलिए नहीं आया क्योंकि इवैल्यूएशन हार्नेस ने कभी भी स्ट्रीमिंग पाथ को टेस्ट नहीं किया था — यानी वह रास्ता जिसे डिवाइस असल में इस्तेमाल करता है।

सुधार वेरिएबल को श्रेड के ज़रिए पास कर दिया गया है, और अब विफलता की स्थिति में स्वास्थ्य कार्यकर्ता से यह कहने के बजाय कि मैनुअल में उसका सवाल शामिल नहीं है, सिस्टम सामान्य तरीके से उत्तर देने पर फॉल बैक कर जाता है।

डिवाइस बनने से पहले हमारे अपने दो माप गलत थे

समस्या दो prompt wordings की तुलना से ऐसा लगा कि एक स्पष्ट रूप से बेहतर है। असल में ऐसा नहीं था।

कारण टेस्ट स्क्रिप्ट ने retrieved context को 2400 characters पर काट (truncate) दिया था जबकि डिवाइस पूरा context भेजता है, इसलिए जो prompt टेस्ट किया जा रहा था वह इस्तेमाल में आ रहा prompt नहीं था। इसके अलावा, evaluation harness ने prompt की अपनी कॉपी रखी हुई थी, जो डिवाइस वाली कॉपी से अलग हो गई थी (drifted), और वह ऐसे wording को स्कोर कर रहा था जिसे डिवाइस अब इस्तेमाल नहीं कर रहा था।

सुधार अब दोनों एप्लीकेशन से prompt और generation settings को इम्पोर्ट करते हैं, जिससे किसी भी बदलाव को अनदेखा रहने के बजाय अगली रन में ही माप लिया जाता है।

तीन बदलाव जिनके परिणाम खराब आए और जिन्हें वापस ले लिया गया

समस्या हर अच्छा विचार आंकड़ों के परीक्षण में खरा नहीं उतरा।

सुधार पेजों को पैराग्राफ के आकार के पैसेज में बांटना इस तरह के retrieval के लिए एक किताबी सुधार है। नापने पर: ग्राउंडिंग 0.67 से गिरकर 0.63 हो गई, मजबूत ग्राउंडिंग वाले उत्तर 31 से घटकर 29 रह गए, और एक उत्तर में सही दवा की जगह गलत दवा आ गई। इसे वापस ले लिया गया। गलत सुने गए शब्दों के लिए शुरुआती करेक्शन लिस्ट ने ध्वनियों को आपस में इतनी आक्रामकता से मिला दिया कि दूध से दस्त बन गया — दूध (milk) से दस्त (diarrhoea) — जिससे 19 में से 6 अच्छे वाक्य खराब हो गए; इसे केवल देखी गई गड़बड़ियों के आधार पर दोबारा बनाने पर 28 में से एक भी वाक्य खराब नहीं होता। और चारों चेकलिस्ट पेजों को अन-रिवर्स करना, जो कि एक स्पष्ट सुधार लग रहा था, मूल्यांकन को 9/10 से गिराकर 8/10 पर ले आया।

परिणाम इस प्रोजेक्ट में अब हर बदलाव को तीन जांचों के आधार पर रखा या हटाया जाता है: 52-प्रश्नों का पेज-दर-पेज सेट, दस-प्रश्नों का मूल्यांकन, और बारह ऑफ-मैनुअल प्रश्न जिन्हें अस्वीकार किया जाना अनिवार्य है।

एक ऐसा दस्तावेज़ जो पढ़ने में सही है पर जिसे कॉपी नहीं किया जा सकता

समस्या हमारे अपने हिंदी PDF से कॉपी किया गया टेक्स्ट टूटा हुआ आता है — चाहिए की जगह चा हए और यदि की जगह द कॉपी होता है — और इसे कुछ समय के लिए यह समझ लिया गया था कि डिवाइस ने कुछ और उत्तर दिया है। ऐसा नहीं था।

कारण डिस्टले के लिए जहाँ कहीं भी वोवेल साइन (vowel sign) को रीऑर्डर किया जाता है, PDF उसके पीछे के कैरेक्टर्स की मैपिंग खो देता है। इस बोर्ड पर मौजूद सभी ग्यारह देवनागरी फॉन्ट्स को आजमाया गया और हर एक में यह समस्या है, जिनमें से ज्यादातर में यह इस्तेमाल हो रहे फॉन्ट से भी बहुत बुरा है, इसलिए यह फॉन्ट की बजाय रेंडरर की समस्या है।

सुधार टेस्ट शीट को PDF के साथ-साथ UTF-8 टेक्स्ट के रूप में भी पब्लिश किया गया है। PDF पढ़ने और प्रिंट करने के लिए है; टेक्स्ट फाइल कॉपी करने के लिए है।

जो समस्याएँ अभी भी खुली हैं, स्पष्ट रूप से

नॉलेज बेस सात मॉड्यूल में से एक है। मॉड्यूल 7 बाल स्वास्थ्य और पोषण को कवर करता है। प्रसव पूर्व देखभाल, प्रसव के बाद रक्तस्राव और गर्भावस्था में एनीमिया इसमें शामिल नहीं हैं, इसलिए उनके बारे में पूछे गए प्रश्नों का खोजने के लिए कोई सही उत्तर मौजूद नहीं है और डिवाइस को ऐसा ही बताने के लिए बनाया गया है। शेष मॉड्यूल को जोड़ना सबसे बड़ा उपलब्ध सुधार है, और यह एक कंटेंट टास्क है, algorithmic टास्क नहीं।

52 में से दो उत्तर गलत हैं और टेस्ट शीट पर गलत के रूप में दर्ज हैं, साथ ही दो रिफ्यूज़ल और तीन ढीले (loose) उत्तर भी हैं। दोनों गलत उत्तर ऐसे पृष्ठों पर रैंकिंग फेलर हैं जिनका विषय आमने-सामने के पन्नों पर चलता है; इनमें से किसी को भी छुपाया नहीं गया है।

अंग्रेजी किताब के विरुद्ध हिंदी में प्रश्न पूछना शेष संरचनात्मक लागत (structural cost) है। अंतर को हाथ से पाटने के लिए आठ vocabulary substitutions की आवश्यकता पड़ी, और हम नहीं जानते कि jury अगली बार किस शब्द का उपयोग करेगी। उसी वॉल्यूम के हिंदी संस्करण को index करने से इस प्रकार की समस्याएं पूरी तरह समाप्त हो जाएंगी, और इस चरण के बाद यह सबसे पहला काम होना चाहिए।

बिक्री से पहले दो **licence** बदलने होंगे: हिंदी वॉइस और जिस वॉइस को इसने रिप्लेस किया था, वे दोनों non-commercial हैं।